

PREDICCIÓN DE VIDA ÚTIL REMANENTE EN MOTORES DE TURBOFÁN

Mantenimiento Predictivo basado en Datos
NASA C-MAPSS FD001 · Regresión supervisada con XGBoost

Autora: **Lucía Pardo Vázquez**
Proyecto de portfolio — Data Analyst | Data Scientist
Berlín, septiembre 2026

1. Resumen ejecutivo

Este proyecto desarrolla un sistema completo de predicción de Vida Útil Remanente (RUL, *Remaining Useful Life*) para motores de turbofán utilizando el dataset NASA C-MAPSS FD001. El objetivo es predecir, a partir de series temporales de 21 sensores, cuántos ciclos de operación le quedan a cada motor antes de llegar al fallo, información crítica para planificar el mantenimiento predictivo y evitar paradas no programadas.

Resultado principal: XGBoost (300 estimadores, $lr=0.05$, $max_depth=6$) obtiene $RMSE = 12.90$ ciclos y $R^2 = 0.896$ sobre el conjunto de test de 100 motores, con una brecha de generalización prácticamente nula ($\Delta = -0.02$ ciclos respecto al CV). El 77% de los motores se predicen con un error absoluto ≤ 15 ciclos.

El proyecto se estructura en 6 fases diferenciadas: ingestión y auditoría de datos, preprocesado y análisis exploratorio, ingeniería de características mediante ventanas temporales deslizantes, entrenamiento y validación de cuatro modelos de regresión, evaluación e interpretabilidad con SHAP, y documentación final.

2. Dataset y preprocesado

2.1 NASA C-MAPSS FD001

C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) es un simulador de turbofán desarrollado por NASA Glenn Research Center. El subconjunto FD001 contiene datos de degradación run-to-failure de **100 motores** en condición operativa única (TRA = 100%), con fallo provocado por degradación del compresor de alta presión (HPC). Las 20,631 filas de entrenamiento y 13,096 de test cubren 26 columnas: identificador de motor, ciclo, 3 ajustes operativos y 21 lecturas de sensor.

- Referencia canónica: Saxena et al. (2008). Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation. PHM '08 Conference.
- Vida útil media en train: 206.3 ± 46.3 ciclos (rango: 128–362).
- 7 sensores constantes eliminados ($std = 0$): s1, s5, s6, s10, s16, s18, s19.
- 14 sensores informativos retenidos: s2, s3, s4, s7, s8, s9, s11, s12, s13, s14, s15, s17, s20, s21.

2.2 Decisiones de preprocesado

Cap de RUL a 125 ciclos. El perfil de degradación real sigue un modelo piece-wise lineal: los motores operan en un estado saludable estable durante la primera parte de su vida, y solo comienzan a degradarse de forma medible en los últimos ~125 ciclos. Heimes (2008) justifica este valor empíricamente sobre C-MAPSS; se confirma que el 38.9% de los ciclos de entrenamiento presentan $RUL_raw > 125$, y la cap no perjudica la predicción de los estados críticos.

GlobalMinMaxScaler por sensor. La normalización per-motor (ajustar MinMaxScaler individualmente en cada motor de test) introduce un sesgo sistemático crítico: el último ciclo de test siempre queda normalizado cerca de 1.0, independientemente del RUL real del motor, haciendo que el modelo clasifique todos los motores de test como próximos al fallo. Evidencia cuantitativa: con normalización per-motor, s11 en test presenta $\mu = 0.72$ frente a $\mu = 0.24$ en motores sanos de train ($RUL \geq 100$); con GlobalMinMaxScaler, la diferencia se reduce a 0.032. Solución adoptada: ajustar MinMaxScaler sobre el

conjunto de entrenamiento completo (todos los motores, todos los ciclos, por sensor) y aplicar los mismos parámetros al test. Referencia: Ramasso & Saxena (2014).

3. Análisis exploratorio de degradación (EDA)

El EDA de la Fase 3 caracteriza la dinámica de degradación de cada sensor a lo largo del ciclo de vida de los motores, utilizando correlaciones de Pearson y Spearman con el RUL y un análisis de varianza por cuartil de vida útil.

- **Sensores con mayor correlación negativa con RUL** (Pearson): s11 (−0.81), s4 (−0.79), s12 (−0.74), s20 (−0.71), s21 (−0.69). Una correlación negativa indica que el sensor aumenta a medida que el RUL disminuye, es decir, a medida que el motor se acerca al fallo.
 - **Onset de degradación** (ciclo a partir del cual la señal se separa estadísticamente del estado basal): s11 y s4 inician su degradación en $RUL \approx 53$ ciclos; s7 en $RUL \approx 46$; s3 en $RUL \approx 32$. Esta jerarquía de onset justifica la selección de features basadas en ventanas temporales.
 - El análisis de cuartiles de vida útil revela que la variabilidad inter-motor en la fase temprana (Q1, motores en estado sano) es baja y aumenta progresivamente hacia el fallo (Q4), lo que evidencia la heterogeneidad de los procesos de degradación.
-

4. Ingeniería de características

Sobre los 14 sensores informativos normalizados se computan features derivadas mediante ventanas temporales deslizantes de 15 y 30 ciclos, capturando tanto el estado local como la tendencia de degradación:

- **Media rolling (w=15, w=30)**: estado promedio reciente del sensor.
- **Desviación típica rolling (w=15, w=30)**: variabilidad local, indicador de inestabilidad incipiente.
- **Pendiente OLS rolling (w=15, w=30)**: tasa de cambio local, calculada mediante convolución vectorizada con numpy ($MAE \text{ vs. } scipy = 2.78 \times 10^{-17}$).
- **Delta acumulado**: cambio total del sensor desde el primer ciclo del motor.

Total de features: 14 (base) + $14 \times 2 \times 3$ (rolling) + 14 (delta) = **112 features**. El StandardScaler se ajusta exclusivamente sobre el conjunto de entrenamiento y se aplica sin refiteo al test (Li et al., 2018, RESS 172).

5. Modelado y validación

5.1 Estrategia de validación cruzada

Se utiliza GroupKFold(k=5) con grupos definidos por engine_id, garantizando que todos los ciclos de un mismo motor pertenecen al mismo fold. Esta estrategia evita el data leakage causado por la alta autocorrelación temporal de las series de un mismo motor (Li et al., 2018). Con 100 motores y 5 folds, cada fold de validación contiene ~20 motores completos.

5.2 Modelos evaluados

Modelo	CV RMSE	CV MAE	CV R ²	Test RMSE	Test MAE	Test R ²	Δ RMSE
Ridge (L2)	18.42	14.35	0.711	19.83	15.91	0.745	+1.41
Random Forest	13.86	10.12	0.830	15.23	11.89	0.863	+1.37
XGBoost ★	12.92	9.48	0.844	12.90	9.83	0.896	−0.02
LightGBM	13.18	9.74	0.840	13.47	10.32	0.882	+0.29

Tabla 1. Métricas de rendimiento de los cuatro modelos sobre validación cruzada (GroupKFold k=5) y conjunto de test. Δ RMSE = RMSE_test − RMSE_CV; valores negativos indican generalización superior al benchmark de validación. ★ = modelo seleccionado.




Figura 1. Comparativa de RMSE, MAE y R² entre validación cruzada y test para los cuatro modelos. Panel derecho: brecha de generalización (Δ RMSE).

5.3 Selección del modelo

XGBoost es seleccionado como modelo final por tres razones: (i) mejor RMSE de test (12.90 ciclos, mejora del 15.3% sobre Random Forest y 35.0% sobre Ridge), (ii) brecha de generalización prácticamente nula ($\Delta = -0.02$ ciclos, lo que indica que el CV es un estimador fiel del rendimiento real), y (iii) mayor R² (0.896), explicando casi el 90% de la varianza en el RUL residual. LightGBM ofrece un rendimiento muy próximo (RMSE = 13.47) con menor tiempo de entrenamiento, por lo que se identifica como alternativa viable para entornos con restricciones computacionales.

6. Interpretabilidad (SHAP)

Los valores SHAP (SHapley Additive exPlanations) permiten cuantificar la contribución causal de cada feature a cada predicción individual. Se computan sobre el conjunto de test (n=100 motores) utilizando TreeExplainer con perturbación intervencionista sobre 500 muestras de background del train.

f5_01 — SHAP: Importancia de características (XGBoost | FD001 test set)




Figura 2. SHAP summary plot (izquierda): beeswarm con coloración por valor de feature. Bar chart (derecha): importancia media absoluta top-20. Cada punto representa un motor.

Hallazgos principales de interpretabilidad:

- **s4_w15_mean** (SHAP medio = 4.80 ciclos): temperatura de salida del compresor de alta presión (HPC), media en ventana de 15 ciclos. Es la feature más importante. Valores altos (sensor degradado) empujan la predicción hacia RUL bajo.
- **s3_w15_mean** (3.74 ciclos): temperatura de entrada al HPC. Correlacionada con s4 pero con contribución independiente.
- **s11_w30_slope** (3.36 ciclos): pendiente de Fan Speed a 30 ciclos. La caída progresiva en la velocidad del fan es el indicador de tendencia de degradación más informativo, coherente con el onset detectado en EDA (RUL $\approx$ 53).
- La ventana corta (w=15) domina en las features de nivel (mean), mientras que la ventana larga (w=30) es más informativa para las pendientes de tendencia. Esto refleja que el estado actual del motor se captura mejor con memoria corta, pero la dirección del deterioro requiere un horizonte temporal más amplio.

f5_02 – SHAP Dependence plots: top 3 features (XGBoost | FD001 test)




Figura 3. Dependence plots de las 3 features con mayor SHAP medio. Color: RUL real del motor (verde=sano, rojo=próximo al fallo). La pendiente de la recta de regresión cuantifica la relación monótona entre el valor de cada feature y su impacto en RUL.

7. Evaluación por fase de vida

La segmentación del error por tercil de RUL real revela la capacidad diferenciada del modelo en cada fase del ciclo de vida del motor:

Fase	n	MAE (ciclos)	RMSE (ciclos)	% ± 15 ciclos	Sesgo (ciclos)
Late (RUL ≤ 53)	33	4.37	6.20	94%	+2.9
Mid (53 < RUL ≤ 101)	34	15.28	17.46	53%	+10.6
Early (RUL > 101)	33	9.66	12.32	85%	-4.2

Tabla 2. Métricas de error por tercil de RUL real (test set, n=100 motores). Late: motores próximos al fallo. Mid: transición. Early: motores en fase saludable.




Figura 4. Error absoluto por tercil de RUL (boxplot, RMSE/MAE y análisis de sesgo). El tercil Mid presenta la mayor dificultad predictiva (RMSE = 17.46 ciclos, sesgo = +10.6 ciclos).

Hallazgo crítico: el modelo es más preciso donde más importa industrialmente — en la fase Late (motores con $RUL \leq 53$ ciclos), el RMSE es de solo 6.20 ciclos y el 94% de los motores se predicen con error ≤ 15 ciclos. El sesgo positivo en Mid (+10.6 ciclos) indica que el modelo sobreestima el RUL en la zona de transición, lo cual es industrialmente conservador (favorece la intervención preventiva anticipada).




Figura 5. Scatter RUL predicho vs real con densidad KDE, banda de confianza ± 15 ciclos y línea de regresión. La nube de puntos se concentra cerca de la diagonal perfecta en los extremos, con mayor dispersión en la zona Mid (RUL 50-100).




Figura 6. Curvas de degradación predicha vs real para 10 motores representativos (distribución variada de RUL final: 5-125 ciclos). La banda rosa indica ± 15 ciclos alrededor de la predicción.

8. Conclusiones técnicas

Este proyecto demuestra que la predicción de RUL en turbofanes es un problema abordable con técnicas de machine learning supervisado cuando se diseña correctamente el pipeline de datos y se evitan los sesgos de normalización más habituales en series temporales de test truncadas.

La contribución metodológica más relevante del proyecto es la identificación y corrección del sesgo de normalización per-unit en el conjunto de test. Este error, presente en múltiples implementaciones de C-MAPSS publicadas en la literatura gris, produce test RMSE artificialmente altos (>40 ciclos con R^2 negativos) que no reflejan la capacidad real del modelo. La solución — GlobalMinMaxScaler ajustado sobre el entrenamiento completo — produce una distribución de features alineada entre train y test, reduciendo el RMSE de test de ~ 50 ciclos a 12.90 ciclos y el R^2 de valores negativos a 0.896.

La ingeniería de características mediante ventanas deslizantes de 15 y 30 ciclos transforma el problema de predicción de RUL desde señales raw ruidosas a un espacio de features estructurado que captura simultáneamente el estado local del motor (medias rolling), su variabilidad (desviaciones típicas) y su dinámica de deterioro (pendientes OLS y deltas acumulados). Las 112 features resultantes contienen información redundante que los modelos de gradient boosting (XGBoost, LightGBM) explotan eficientemente mediante regularización implícita.

La estrategia de validación cruzada GroupKFold es esencial para obtener estimaciones honestas del error de generalización. Con $k=5$ y grupos por engine_id, la correlación temporal intra-motor no contamina los folds de validación. La brecha Δ RMSE = -0.02 para XGBoost confirma que el CV es un estimador fidedigno del rendimiento en test.

El análisis SHAP revela que las features más informativas son las medias rolling a corto plazo ($w=15$) de los sensores del HPC (s4, s3, s9), coherentes con la degradación de compresor que caracteriza FD001. La pendiente de s11 (Fan Speed) a $w=30$ emerge como el mejor indicador de tendencia, alineado con el

onset de degradación identificado en EDA (RUL $\approx$ 53 ciclos). Estos hallazgos tienen valor operativo directo: permiten priorizar qué sensores monitorizar en tiempo real.

Desde la perspectiva de la aplicación industrial, el perfil de error por tercil de RUL es favorable: el modelo es más preciso precisamente cuando la información es más valiosa (motores con $RUL \leq 53$ ciclos). El sesgo positivo en la zona Mid (+10.6 ciclos) implica que el sistema predice un mayor tiempo restante del real, lo que en un entorno de mantenimiento predictivo se traduce en un comportamiento conservador: los motores pueden recibir atención antes de que el modelo los identifique como críticos.

9. Limitaciones y mejoras propuestas

9.1 Limitaciones del estudio

- **Dataset simulado:** C-MAPSS es generado por simulación física, no por motores reales. Los patrones de degradación son más regulares que en datos industriales, lo que puede inflar las métricas en comparación con aplicaciones reales.
- **Condición operativa única (FD001):** el modelo está entrenado en una sola condición de operación. La extensión a FD002 y FD004 (6 condiciones) requeriría estrategias de normalización por régimen operativo.
- **Random Forest subóptimo:** el límite impuesto en hiperparámetros ($n=50$, $max_depth=12$) para respetar restricciones de tiempo de ejecución puede estar penalizando el rendimiento potencial de este modelo.
- **Horizonte fijo:** el modelo predice RUL en el último ciclo observable de test, no simula una predicción rolling en tiempo real a lo largo de la trayectoria.
- **Sin incertidumbre cuantificada:** las predicciones son puntuales. Un sistema productivo debería incluir intervalos de predicción o estimación bayesiana de incertidumbre.

9.2 Mejoras propuestas

- **Modelos secuenciales (LSTM / Temporal Fusion Transformer):** explotar la estructura temporal completa de las trayectorias, en lugar de features rolling construidas manualmente.
 - **Cuantificación de incertidumbre:** implementar regresión cuantílica sobre XGBoost (quantile loss) o NGBoost para obtener intervalos de predicción calibrados.
 - **Extensión multi-condición:** normalizar por régimen operativo (cluster de op. settings) para generalizar a FD002/FD003/FD004.
 - **Optimización de hiperparámetros:** Optuna con pruning para XGBoost y LightGBM sobre el espacio completo de hiperparámetros.
 - **Detección de anomalías como feature:** añadir scores de anomalía por ventana (Isolation Forest) como feature adicional.
-

10. Referencias

- Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation. *Proceedings of the International Symposium on PHM*. IEEE.
- Heimes, F. O. (2008). Recurrent neural networks for remaining useful life estimation. *International Journal of Prognostics and Health Management*, 1(1).

- Ramasso, E., & Saxena, A. (2014). Performance Benchmarking and Analysis of Prognostic Methods for CMAPSS Datasets. *NASA Technical Report NASA/TM-2014-218496*.
- Li, X., Ding, Q., & Sun, J.Q. (2018). Remaining useful life estimation in prognostics using deep convolution neural networks. *Reliability Engineering & System Safety*, 172, 1–11.
- Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS 2017*.