

PREDICCIÓN DE VIDA ÚTIL REMANENTE EN MOTORES DE TURBOFÁN

Mantenimiento Predictivo basado en Datos

NASA C-MAPSS FD001 · Regresión y clasificación supervisada · Modelo:
Random Forest

Autora: **Lucía Pardo Vázquez**

Proyecto de portfolio — Data Analyst | Data Scientist

Berlín, septiembre 2026

1. Resumen ejecutivo

Este proyecto desarrolla un sistema completo de predicción de Vida Útil Remanente (RUL, *Remaining Useful Life*) para motores de turbofán utilizando el dataset NASA C-MAPSS FD001, con dos objetivos complementarios: (1) predecir cuántos ciclos de operación le quedan a cada motor mediante regresión, y (2) clasificar si un motor está en zona de riesgo inminente de fallo ($RUL \leq 30$ ciclos), priorizando Recall sobre Precision por el coste asimétrico de un falso negativo en mantenimiento predictivo.

Resultado principal (regresión): Random Forest obtiene $RMSE = 11.04$ ciclos y $R^2 = 0.924$ sobre el conjunto de test de 100 motores, con una brecha de generalización de -1.83 ciclos respecto al CV. El 85% de los motores se predicen con un error absoluto ≤ 15 ciclos.

Resultado principal (clasificación): LogisticRegression alcanza $Recall = 0.960$ en test (prácticamente todos los motores en zona de riesgo detectados) con $Precision = 0.923$, $F1 = 0.941$ y $ROC-AUC = 0.9973$.

El proyecto se estructura en 7 fases: carga y auditoría de datos con normalización canónica (Fase 0), inspección exploratoria extendida a los 4 subdatasets C-MAPSS (Fase 1), ingeniería de características mediante ventanas temporales deslizantes (Fase 2), análisis de degradación (Fase 3), entrenamiento y validación de modelos de regresión y clasificación (Fase 4), evaluación e interpretabilidad con SHAP (Fase 5), y mejoras de rigor estadístico — comparación pareada de modelos, censura, PHM score, heterocedasticidad, ablación de ventanas (Fase 7).

Nota metodológica. Una auditoría posterior a la primera versión de este proyecto encontró y corrigió una fuga de datos (*data leakage*) en la normalización de sensores del conjunto de test — ver sección 2.2. Los números de este informe corresponden a la versión corregida del pipeline.

2. Dataset y preprocesado

2.1 NASA C-MAPSS FD001

C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) es un simulador de turbofán desarrollado por NASA Glenn Research Center. El subconjunto FD001 contiene datos de degradación run-to-failure de **100 motores** en condición operativa única (Sea Level), con fallo provocado por degradación del compresor de alta presión (HPC). Las 20,631 filas de entrenamiento y 13,096 de test cubren 26 columnas: identificador de motor, ciclo, 3 ajustes operativos y 21 lecturas de sensor.

- Referencia canónica: Saxena et al. (2008). Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation. PHM '08 Conference.
- Vida útil media en train: 206.3 ± 46.3 ciclos (rango: 128–362).
- 7 sensores constantes eliminados ($std < 0.01$): s1, s5, s6, s10, s16, s18, s19.
- 14 sensores informativos retenidos: s2, s3, s4, s7, s8, s9, s11, s12, s13, s14, s15, s17, s20, s21.

2.2 Decisiones de preprocesado

Cap de RUL a 125 ciclos. El perfil de degradación real sigue un modelo piece-wise lineal: los motores operan en un estado saludable estable durante la primera parte de su vida, y solo comienzan a degradarse de forma medible en los últimos ciclos. Heimes (2008) justifica este valor empíricamente sobre C-MAPSS.

MinMaxScaler global, no per-motor. La normalización per-motor (ajustar un MinMaxScaler individualmente en cada motor de test) introduce un sesgo sistemático crítico: el último ciclo observado de test siempre queda normalizado cerca de 1.0, independientemente del RUL real del motor, haciendo que el modelo interprete todo motor de test como próximo al fallo. Evidencia cuantitativa (Fase 0): con normalización per-motor, s11 en el último ciclo de test presenta $\mu \approx 0.72$ frente a $\mu \approx 0.32$ en motores sanos de train ($RUL \geq 100$); con MinMaxScaler global (fit solo en train), la diferencia se reduce a $\mu \approx 0.44$, un 69% menos de sesgo. Solución adoptada: ajustar el escalador sobre el conjunto de entrenamiento completo (todos los motores, todos los ciclos, por sensor) y aplicar los mismos parámetros al test — la práctica estándar de *held-out evaluation* (Hastie, Tibshirani & Friedman, 2009).

Extensión a FD002-FD004. Estos subdatasets combinan 6 condiciones operacionales (altitud, Mach, TRA), frente a la condición única de FD001/FD003 — un MinMaxScaler global mezclaría en la misma escala mediciones físicamente distintas. Fase 0 agrupa los 3 *op_setting* en 6 regímenes vía k-means (fit solo en train) y ajusta un MinMaxScaler independiente por régimen. Ver sección 3.2 para la comparativa completa de los 4 subdatasets; el modelado (secciones 4-7) se mantiene enfocado en FD001, el subdataset de referencia más limpio para esta iteración.

3. Análisis exploratorio de degradación (EDA)

3.1 FD001 en profundidad

El EDA de la Fase 3 caracteriza la dinámica de degradación de cada sensor a lo largo del ciclo de vida de los motores, utilizando correlaciones de Pearson y Spearman con el RUL crudo y un análisis de varianza intra- vs. inter-motor.

- **Sensores con mayor correlación absoluta con RUL** (Pearson): s11 (-0.696); s4 (-0.679); s12 (+0.672); s7 (+0.657); s15 (-0.643).
- **Onset de degradación** (ciclo a partir del cual la señal supera 2σ del valor basal, $RUL > 200$): s3 en $RUL \approx 32$; s7 en $RUL \approx 46$; s12 en $RUL \approx 50$; s4 en $RUL \approx 53$; s11 en $RUL \approx 53$. Esta jerarquía justifica las ventanas temporales de 15 y 30 ciclos usadas en la ingeniería de características.
- El análisis de cuartiles de vida útil revela que la variabilidad inter-motor en la fase temprana (Q1, motores en estado sano) es baja y aumenta progresivamente hacia el fallo (Q4), evidenciando la heterogeneidad de los procesos de degradación.

3.2 Comparativa de los 4 subdatasets (extensión, Fase 1)

La normalización de Fase 0 se extendió a FD002-FD004 (sección 2.2); esta extensión de Fase 1 compara los 4 subdatasets sin entrenar modelos sobre ellos:

Subdataset	Motores tr/te	Cond. op.	Modos fallo	Vida media $\pm$ std	Sensores inform.	Normalización
FD001	100/100	1	1	206 $\pm$ 46	14	global
FD002	260/259	6	1	207 $\pm$ 47	20	per_condition
FD003	100/100	1	2	247 $\pm$ 86	15	global
FD004	249/248	6	2	246 $\pm$ 73	20	per_condition

Tabla 0. Comparativa de los 4 subdatasets NASA C-MAPSS. FD002/FD004 retienen más sensores informativos porque su varianza depende del régimen operacional, no solo de la degradación — un sensor casi constante en FD001 (condición única) puede variar sustancialmente entre 6 regímenes.

4. Ingeniería de características

Sobre los 14 sensores informativos normalizados se computan features derivadas mediante ventanas temporales deslizantes de 15 y 30 ciclos, capturando tanto el estado local como la tendencia de degradación:

- **Media rolling (w=15, w=30):** estado promedio reciente del sensor.
- **Desviación típica rolling (w=15, w=30):** variabilidad local, indicador de inestabilidad incipiente.
- **Pendiente OLS rolling (w=15, w=30):** tasa de cambio local, calculada mediante convolución vectorizada.
- **Delta acumulado:** cambio total del sensor desde el primer ciclo del motor.

Total de features: 14 (base) + 14×2×3 (rolling) + 14 (delta) = **112 features**. Un conjunto extendido (238 features, ventanas 15/30/50 + min/max + delta de primer orden) se comparó empíricamente vía GroupKFold + test oficial: gana en CV (11.29 vs. 12.72 RMSE) pero pierde en test (12.66 vs. 11.98) — el patrón sesgo-varianza esperado (Hastie et al., 2009), que confirma la elección de 112 features. El StandardScaler se ajusta exclusivamente sobre el conjunto de entrenamiento y se aplica sin refiteo al test (Li, Ding & Sun, 2018).

5. Modelado y validación

5.1 Estrategia de validación cruzada

Se utiliza GroupKFold(k=5) con grupos definidos por engine_id, garantizando que todos los ciclos de un mismo motor pertenecen al mismo fold. Esta estrategia evita el data leakage causado por la alta autocorrelación temporal de las series de un mismo motor (Li, Ding & Sun, 2018). Con 100 motores y 5 folds, cada fold de validación contiene ~20 motores completos.

5.2 Regresión: modelos evaluados

Modelo	CV RMSE	CV MAE	CV R ²	Test RMSE	Test MAE	Test R ²	Δ RMSE
Ridge (L2)	16.39	12.99	0.845	14.93	11.66	0.861	-1.46
Random Forest ★	12.87	9.58	0.905	11.04	8.14	0.924	-1.83
XGBoost	12.68	9.23	0.908	11.32	8.19	0.920	-1.36
LightGBM	12.74	9.20	0.907	12.05	8.55	0.910	-0.68

Tabla 1. Métricas de rendimiento de los cuatro modelos de regresión sobre validación cruzada (GroupKFold k=5) y conjunto de test. $\Delta \text{RMSE} = \text{RMSE}_{\text{test}} - \text{RMSE}_{\text{CV}}$; valores negativos indican generalización superior al benchmark de validación. ★ = modelo seleccionado.




Figura 1. Comparativa de RMSE, MAE y R^2 entre validación cruzada y test para los cuatro modelos de regresión. Panel derecho: brecha de generalización (Δ RMSE).

5.3 Selección del modelo de regresión

Random Forest es seleccionado como modelo final por su menor RMSE de test (11.04 ciclos, una mejora del 26.0% sobre el peor modelo evaluado, Ridge (L2)) y su R^2 de 0.924, explicando 92% de la varianza en el RUL residual. Su brecha de generalización ($\Delta = -1.83$ ciclos) indica que el CV es un estimador razonablemente fiel del rendimiento real. XGBoost ofrece un rendimiento cercano (RMSE = 11.32), por lo que se identifica como alternativa viable si difieren las prioridades de interpretabilidad o coste computacional.

5.4 Clasificación de zona de riesgo (objetivo 2)

En paralelo a la regresión de RUL, se entrena un clasificador binario para *early_failure* ($RUL \leq 30$ ciclos = fallo inminente), usando las mismas 112 features, el mismo protocolo GroupKFold($k=5$) y el mismo test oficial. Las clases están desbalanceadas (~17.5% positivos en train), por lo que los 4 modelos — Logistic Regression, Random Forest, XGBoost y LightGBM — incorporan peso de clase balanceado (*class_weight="balanced" / scale_pos_weight*).

Modelo	CV F1	CV Recall	CV ROC-AUC	Test F1	Test Recall	Test Precision	Test ROC-AUC
LogisticRegression ★	0.907	0.948	0.9951	0.941	0.960	0.923	0.9973
RandomForest	0.913	0.936	0.9947	0.941	0.960	0.923	0.9931
XGBoost	0.925	0.945	0.9963	0.941	0.960	0.923	0.9984
LightGBM	0.926	0.945	0.9964	0.941	0.960	0.923	0.9979

Tabla 1b. Métricas de clasificación *early_failure* sobre validación cruzada y test. ★ = mejor modelo por Recall en test (prioridad de seguridad industrial: un fallo inminente no detectado es más costoso que una revisión de más).

Por qué Recall y no Accuracy. En mantenimiento predictivo, un falso negativo (fallo inminente no detectado) es mucho más costoso que un falso positivo (una revisión de más). Con Recall = 0.960 en test, LogisticRegression identifica correctamente prácticamente todos los motores en zona de riesgo, manteniendo Precision = 0.923.

6. Interpretabilidad (SHAP)

Los valores SHAP (*SHapley Additive exPlanations*) permiten cuantificar la contribución causal de cada feature a cada predicción individual. Se computan sobre el conjunto de test (n=100 motores) para el modelo de regresión seleccionado (Random Forest) utilizando TreeExplainer con perturbación intervencionista sobre muestras de background del train.




Figura 2. SHAP summary plot (izquierda): beeswarm con coloración por valor de feature. Bar chart (derecha): importancia media absoluta top-20. Cada punto representa un motor.

Hallazgos principales de interpretabilidad:

- **s11_w30_slope** (SHAP medio = 3.69 ciclos): Ps30 — Static pressure HPC — pendiente OLS móvil, ventana 30 ciclos. Es la feature más importante.
- **s2_w15_mean** (3.16 ciclos): T24 — Temp. LPC outlet — media móvil, ventana 15 ciclos.
- **s4_w15_mean** (2.83 ciclos): T50 — Temp. LPT outlet — media móvil, ventana 15 ciclos.
- El feature más importante es una *pendiente* (tendencia), no un nivel absoluto — coherente con que la velocidad de degradación es más informativa que el valor puntual del sensor, y con la jerarquía de onset de degradación de la sección 3.1.

f5_02 – SHAP Dependence plots: top 3 features (test set)




Figura 3. Dependence plots de las 3 features con mayor SHAP medio. Color: RUL real del motor (verde=sano, rojo=próximo al fallo). La pendiente de la recta de regresión cuantifica la relación monótona entre el valor de cada feature y su impacto en RUL.

7. Evaluación por fase de vida

La segmentación del error por tercil de RUL real (Random Forest, test) revela la capacidad diferenciada del modelo en cada fase del ciclo de vida del motor:

Fase	n	MAE (ciclos)	RMSE (ciclos)	% ± 15 ciclos	Sesgo (ciclos)
Late (RUL $\leq$ 53)	33	4.58	5.71	97%	+3.0
Mid (53<RUL $\leq$ 101)	34	12.54	15.33	68%	+7.3
Early (RUL>101)	33	7.17	9.74	91%	-3.8

Tabla 2. Métricas de error por tercil de RUL real (test set, n=100 motores). Late: motores próximos al fallo. Mid: transición. Early: motores en fase saludable.




Figura 4. Error absoluto por tercil de RUL (boxplot, RMSE/MAE y análisis de sesgo). El tercil Mid presenta la mayor dificultad predictiva (RMSE = 15.33 ciclos, sesgo = +7.3 ciclos).

Hallazgo: el modelo es más preciso donde más importa industrialmente — en la fase Late (motores próximos al fallo), el RMSE es de solo 5.71 ciclos y el 97% de los motores se predicen con error ≤ 15 ciclos. El sesgo es positivo en las fases Late y Mid (+3.0 y +7.3 ciclos): el modelo tiende a sobreestimar el RUL cerca del fallo — más seguro que subestimarlos, pero conviene tenerlo presente al calibrar umbrales de alarma.




Figura 5. Scatter RUL predicho vs real con densidad KDE, banda de confianza ± 15 ciclos y línea de regresión.

f5_03 — Degradación predicha vs. real: 10 motores representativos




Figura 6. Curvas de degradación predicha vs real para 10 motores representativos (distribución variada de RUL final). La banda rosa indica ± 15 ciclos alrededor de la predicción.

8. Conclusiones técnicas

Este proyecto demuestra que la predicción de RUL en turbofanes es un problema abordable con técnicas de machine learning supervisado cuando se diseña correctamente el pipeline de datos y se evitan los sesgos de normalización más habituales en series temporales de test truncadas.

La contribución metodológica más relevante del proyecto es la identificación y corrección del sesgo de normalización per-motor en el conjunto de test (sección 2.2): un MinMaxScaler ajustado independientemente en cada motor de test produce una señal espuria de "cerca del fallo" en todo el test set, independientemente del RUL real. La solución — un único escalador ajustado sobre el entrenamiento completo — elimina ese sesgo y produce una comparación train/test estadísticamente honesta.

La ingeniería de características mediante ventanas deslizantes de 15 y 30 ciclos transforma el problema de predicción de RUL desde señales crudas ruidosas a un espacio de features estructurado que captura simultáneamente el estado local del motor (medias rolling), su variabilidad (desviaciones típicas) y su dinámica de deterioro (pendientes OLS y deltas acumulados). De los cuatro modelos evaluados, Random Forest obtiene el mejor equilibrio entre ajuste y generalización sobre estas 112 features.

La estrategia de validación cruzada GroupKFold es esencial para obtener estimaciones honestas del error de generalización. Con $k=5$ y grupos por engine_id, la correlación temporal intra-motor no contamina los folds de validación.

El análisis SHAP revela que Ps30 es la variable más informativa para el modelo seleccionado, con las pendientes de tendencia (velocidad de cambio) generalmente más informativas que los niveles absolutos — hallazgo con valor operativo directo: permite priorizar qué sensores y qué transformaciones (nivel vs. tendencia) monitorizar en tiempo real.

El objetivo de clasificación (zona de riesgo) se resuelve con alta fiabilidad — Recall = 0.960 en test — confirmando que las mismas 112 features que sirven para la regresión de RUL son suficientes para una tarea de alarma binaria, sin necesidad de un pipeline de features independiente.

Desde la perspectiva de la aplicación industrial, el perfil de error por tercil de RUL es favorable: el modelo de regresión es más preciso precisamente cuando la información es más valiosa (motores próximos al fallo), y el clasificador prioriza explícitamente no dejar pasar fallos inminentes — ambos comportamientos son conservadores desde el punto de vista del mantenimiento predictivo.

9. Limitaciones y mejoras propuestas

9.1 Limitaciones del estudio

- **Dataset simulado:** C-MAPSS es generado por simulación física, no por motores reales. Los patrones de degradación son más regulares que en datos industriales, lo que puede inflar las métricas en comparación con aplicaciones reales.
- **Modelado limitado a FD001:** aunque Fase 0/1 extendieron el preprocesado y el EDA a los 4 subdatasets (incluida la normalización por régimen operacional para FD002/FD004, sección 2.2/3.2), el modelado supervisado (Fases 4-7) se mantiene enfocado en FD001 por decisión de alcance de esta iteración — es el subdataset más limpio para desarrollo inicial (1 condición, 1 modo de fallo).
- **Horizonte fijo:** el modelo predice RUL en el último ciclo observable de test, no simula una predicción rolling en tiempo real a lo largo de la trayectoria.
- **Sin incertidumbre cuantificada:** las predicciones de regresión son puntuales. Un sistema productivo debería incluir intervalos de predicción o estimación bayesiana de incertidumbre.
- **Umbral de clasificación fijo (0.5):** el clasificador no se calibró para un punto de operación específico de Recall/Precision; un despliegue real debería ajustar el umbral según el coste real de falsos negativos vs. falsos positivos.

9.2 Mejoras propuestas

- **Modelos secuenciales (LSTM / Temporal Fusion Transformer):** explotar la estructura temporal completa de las trayectorias, en lugar de features rolling construidas manualmente.
- **Cuantificación de incertidumbre:** implementar regresión cuantílica o NGBoost para obtener intervalos de predicción calibrados.
- **Extensión del modelado a FD002-FD004:** reutilizar la normalización por régimen ya implementada en Fase 0 para entrenar y evaluar los mismos modelos sobre los subdatasets multi-condición.
- **Optimización de hiperparámetros:** búsqueda sistemática (p.ej. Optuna con pruning) para XGBoost y LightGBM sobre el espacio completo de hiperparámetros.
- **Detección de anomalías como feature:** añadir scores de anomalía por ventana (Isolation Forest) como feature adicional.

10. Referencias

- Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation. *Proceedings of the International Conference on Prognostics and Health Management (PHM 2008)*, Denver, CO.

- Heimes, F. O. (2008). Recurrent neural networks for remaining useful life estimation. *International Conference on Prognostics and Health Management (PHM 2008)*.
- Ramasso, E., & Saxena, A. (2014). Performance Benchmarking and Analysis of Prognostic Methods for CMAPSS Datasets. *International Journal of Prognostics and Health Management*, 5(2). DOI: 10.36001/ijphm.2014.v5i2.2236.
- Li, X., Ding, Q., & Sun, J.-Q. (2018). Remaining useful life estimation in prognostics using deep convolution neural networks. *Reliability Engineering & System Safety*, 172, 1–11.
- Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS 2017*.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.